

Inferencia estadística y regresión logística

**Clase 6 · Inferencia con bootstrap y valor p ·
Regresión logística**

Daniela Opitz

INF-396 · Departamento de Informática · UTFSM · viernes 2 de octubre, 2026

Avisos

- ▶ **El Certamen 1 es el viernes 9 de octubre, en el horario de clases: unidades 1 a 5, incluida la regresión lineal y la inferencia de hoy.**
- ▶ La guía de estudio está publicada en el repositorio: 37 preguntas de alternativas, desarrollo y cálculo, ordenadas por tipo, con el temario por unidad al inicio.
- ▶ El certamen es escrito e individual, sin computador ni apuntes. Se puede usar calculadora; las hojas de desarrollo las entrega la profesora.
- ▶ La Tarea 1 está en corrección; las notas se publican por Aula.

Contenidos de la clase

Bloque 1 · Inferencia: ¿real o azar?

- 1 El azar tiene forma: la normal
- 2 Un número se mueve: el error estándar
- 3 Primer uso: el intervalo de confianza
- 4 La pendiente se mueve: bootstrap
- 5 Segundo uso: la prueba y el valor p

Bloque 2 · Regresión logística: ¿sí o no?


- 1 Una respuesta que es sí o no
- 2 Por qué la recta no sirve
- 3 La recta dentro de una S; cómo se lee e^b
- 4 El mismo summary, con varias variables
- 5 Clasificar: el umbral y los dos errores

Dos bloques de 70 minutos. El primero responde si la pendiente de la clase 04 es real o azar; el segundo modela una respuesta que es sí o no.

Bloque 1 · ¿De dónde salen las otras muestras?


Primero, un repaso de la recta de la clase 04; después, cuánto se movería esa recta con otra muestra

La EOD es un sorteo



SECTRA sorteó 18.264 hogares entre los 2.051.310 del Gran Santiago. Otro sorteo habría dado otra tabla y otros números: cada cifra que calculamos es el resultado de un sorteo. La pregunta de hoy es cuánto se movería.

Repaso: la recta de la clase 04



Cada punto es una comuna, con su ingreso medio del hogar y la duración media de sus viajes, ponderados por el factor. La recta de mínimos cuadrados: $\text{duración} = 38,3 - 4,8 \cdot \text{ingreso}$. Por cada millón de pesos más de ingreso medio, los viajes duran 4,8 minutos menos. Son 45 comunas.

Repaso: el summary de la clase 04


```
=====
                        OLS Regression Results
=====
Dep. Variable:          duracion      R-squared:                0.117
Model:                  OLS           Adj. R-squared:           0.097
Method:                 Least Squares  F-statistic:              5.707
Date:                   Fri, 04 Sep 2026  Prob (F-statistic):      0.0214
Time:                   12:37:03       Log-Likelihood:          -139.50
No. Observations:       45            AIC:                     283.0
Df Residuals:           43            BIC:                     286.6
Df Model:                1
Covariance Type:        nonrobust
=====
                        coef      std err          t      P>|t|      [0.025      0.975]
-----
const                38.3352      1.773      21.622      0.000      34.760      41.911
ingreso              -4.8146      2.015      -2.389      0.021      -8.879      -0.750
=====
Omnibus:                2.948      Durbin-Watson:           1.936
Prob(Omnibus):           0.229      Jarque-Bera (JB):        2.776
Skew:                    0.556      Prob(JB):                0.250
Kurtosis:                2.504      Cond. No.                4.12
=====
```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

La misma recta en statsmodels. En la clase 04 leímos los coeficientes (38,3 y -4,8) y el intervalo de confianza [-8,9; -0,75]. Hoy veremos de dónde salen el error estándar (std err), la t, el valor p = 0,021 y el 95% del intervalo. La pregunta: ¿la pendiente de -4,8 es real, o es azar de las 45 comunas?


Descriptiva e inferencia



La descriptiva habla de la tabla que tenemos; la inferencia, de la población de la que salió, con su incertidumbre. Dos preguntas: cuánto vale, y si es real o azar.


1. El azar tiene forma

Todo número que sale de una muestra se mueve;
el error estándar mide cuánto, y se usa de dos formas




Probabilidad, el lenguaje de la incertidumbre: variables aleatorias y distribuciones

Una variable aleatoria y su distribución



La duración del próximo viaje depende del azar: es una variable aleatoria. Su distribución dice qué valores toma y con qué frecuencia: en la población, el histograma. La esperanza es su media.



La duración de un viaje no es normal



Esta slide habla de la variable, un viaje a la vez, no de promedios. La duración de un viaje tiene cola larga (asimetría 5,3) y no sigue una campana; su logaritmo sí se acerca a ella, y esa es la razón de fondo del logaritmo de la clase 04. El azar de esta variable tiene forma, pero no de campana.


La media de 100 viajes sí es una campana

Dos variables aleatorias: la duración de un viaje, y la media de una muestra de 100 viajes



Ahora hablamos de promedios. A la izquierda, otra vez la variable: la duración de un viaje, asimétrica. A la derecha, la media de 100 viajes, calculada 2.000 veces con 100 viajes distintos: su valor depende de qué viajes cayeron en la muestra, así que también es una variable aleatoria, y su distribución sí es una campana. Esa campana es la distribución normal.

La normal: la forma de los promedios




La campana de la slide anterior, con nombre. Tiene dos parámetros: μ , su media, y σ , su desviación estándar, y el 95% de sus valores cae a menos de $1,96 \sigma$ de μ . Es la distribución de la inferencia porque los promedios la siguen, aunque la variable que se promedia no lo haga; ese 1,96 vuelve en los intervalos de confianza.

Notar que la regla 68-95-99,7 es una propiedad de la normal, no de cualquier variable: en la duración de un viaje, el 87% de los valores queda a menos de 1σ de la media, y $\mu - 1,96 \sigma$ es negativo, sin sentido para una duración.


2. Un número se mueve

Todo número que sale de una muestra se mueve;
el error estándar mide cuánto, y se usa de dos formas




Muestra y población: una muestra es una de muchas posibles

Dos muestras, dos medias




Hoy tratamos los 113 mil viajes de la EOD como si fueran la población, para poder muestrear muchas veces. Cada muestra de 100 viajes da otra media; ninguna es la poblacional.

La distribución muestral de la media



2.000 muestras, 2.000 medias: su histograma es la distribución muestral, centrada en la media real. Su desviación es el error estándar: cuánto se mueve la media de una muestra a otra. Se pudo hacer porque aquí tenemos la población.

Desviación estándar y error estándar



La desviación estándar σ describe los datos: cuánto varía la duración de un viaje a otro. El error estándar $EE(\bar{x}) = \sigma/\sqrt{n}$ describe el estimador: cuánto varía la media de una muestra a otra. Es la desviación estándar de la distribución muestral; por eso es más chico, y baja con n .

El error estándar, desde una sola muestra

$$EE(\bar{x}) = \frac{\sigma}{\sqrt{n}} \approx \frac{s}{\sqrt{n}}$$

$\sigma = 36,0$ min: desviación estándar de la duración en la población (113.591 viajes)

$s = 36,2$ min: la misma desviación estándar, pero en la única muestra de 100 viajes

$n = 100$: el tamaño de la muestra · $\bar{x}$: la media de esa muestra

Lo que hicimos recién

2.000 muestras de 100 viajes:
la desviación de sus medias

3,7 min

La fórmula, con la población

$$\sigma / \sqrt{n} = 36,0 / 10$$

3,6 min

La vida real: una muestra


$$s / \sqrt{n} = 36,2 / 10$$

(sin ver la población)

3,6 min

Las 2.000 muestras fueron posibles porque aquí tenemos la población. En la vida real hay una sola muestra y ninguna población a la vista: la fórmula da casi el mismo número desde esa muestra, con s en lugar de σ .


El teorema central del límite



La media de una muestra se distribuye normal alrededor de la media real, con desviación $\sigma/\sqrt{n}$, aunque la variable no sea normal. Por eso la normal es la distribución de la inferencia: los promedios lo son, y la regla del $1,96 \sigma$ se les puede aplicar.


3. Primer uso del error estándar: el intervalo

Todo número que sale de una muestra se mueve;
el error estándar mide cuánto, y se usa de dos formas



Del error estándar a un rango honesto

De la distribución muestral al intervalo



Paso 1: por el TCL las medias muestrales son normales, así que el 95% cae a menos de 1,96 EE de μ . Paso 2, la misma frase al revés: μ está a menos de 1,96 EE de la media de mi muestra en el 95% de las muestras. Ese rango es el intervalo.

El intervalo de confianza del 95%

El rango que, en el 95% de las muestras, atrapa la media de la población


$$\bar{x} \pm 1,96 \cdot \frac{s}{\sqrt{n}}$$

$\bar{x}$: la media de la muestra · $s/\sqrt{n}$: el error estándar

1,96: el múltiplo de la normal que deja el 95% al centro

Se lee sobre el procedimiento: si repitiéramos el muestreo, el 95% de los intervalos atraparía la media real. Este intervalo en particular la atrapa o no; nunca sabremos cuál de los dos.


Comprobado con la población



100 muestras de 100 viajes, 100 intervalos: los rojos no atrapan la media. Cerca del 95% lo hace; con cola larga y $n = 100$, un poco menos.

4. La pendiente también se mueve


Todo número que sale de una muestra se mueve;
el error estándar mide cuánto, y se usa de dos formas



La recta del repaso: duración = $a + b \cdot \text{ingreso}$, con $b = -4,8$ minutos por millón y 45 comunas (el coef del ingreso en el summary). Otra muestra de comunas daría otra b . ¿Cuánto se mueve?

Qué es el bootstrap


Bootstrap (Efron y Tibshirani, 1993): tratar la muestra como si fuera la población y sacar de ella muchas muestras nuevas del mismo tamaño, con reemplazo, para ver cuánto se mueve la pendiente



Sacar con reemplazo no es quitar una comuna y poner otra: es devolver la comuna sacada a la bolsa antes de sacar la siguiente. Por eso una misma comuna puede salir varias veces, y otra ninguna.


No hay una población de comunas de donde sacar otra muestra, así que la muestra hace de población: se sacan de ella muestras nuevas de 45, con reemplazo, y se mira cuánto cambia la pendiente entre ellas. Sin reemplazo no serviría: 45 de 45 son siempre las mismas 45.

Otra remuestra, otra recta




Cada remuestra da una recta y cada recta una pendiente: 30 rectas, 30 pendientes. Las 30 son solo para ver la idea; para ver la forma completa hacen falta más, y la siguiente slide dice cuántas y por qué.

Con 3 comunas, 10 remuestras posibles



Con tres comunas A, B y C, una remuestra saca tres con reemplazo. El orden no importa, porque el mismo conjunto de puntos da la misma recta: ABA es lo mismo que AAB. Quedan 10 conjuntos posibles: 3 con una sola comuna repetida (sin recta), 6 con una repetida y otra distinta, y 1 con las tres. Con 45 comunas el mismo conteo da 5×10^{25} remuestras posibles: las 2.000 que sacamos son todas distintas.

¿Por qué 2.000 remuestras, y no 30?



Con 30 remuestras el histograma es tosco y el error estándar todavía se mueve de una corrida a otra; desde unas 2.000 deja de cambiar, y esa estabilidad es lo que hace falta para medirlo. Como hay 5×10^{25} remuestras posibles, las 2.000 no agotan nada: son una fracción ínfima, todas distintas.


Remuestrear los datos

```
from sklearn.utils import resample

pendientes = []
for i in range(2000):
    x_r, y_r = resample(x, y, replace=True, random_state=i)
    pendientes.append(pendiente_ols(x_r, y_r))
np.percentile(pendientes, [2.5, 97.5])
```


- resample saca las 45 filas con reemplazo y OLS ajusta la recta de cada remuestra. Las 2.000 pendientes forman la distribución muestral de la pendiente, sin fórmulas ni supuestos. `scipy.stats.bootstrap` hace lo mismo en una línea; está en el notebook.

La distribución de la pendiente



Con bootstrap, el histograma: una campana alrededor de la pendiente observada, cuya desviación es el error estándar de la pendiente. Sin bootstrap, la campana punteada: la fórmula de statsmodels, que viene en la siguiente slide. Casi ninguna remuestra llega al 0.

El intervalo bootstrap



Ordenar las 2.000 pendientes: la número 50 desde abajo es el percentil 2,5 y la número 50 desde arriba, el 97,5. Entre ambas queda el 95% central de las remuestras, y ese es el intervalo. No supone forma de campana: lo lee directo del histograma.

La fórmula de statsmodels: std err

	coeficiente	error estándar				
	coef	std err	t	P> t	[0.025	0.975]
const	38.3352	1.773	21.622	0.000	34.760	41.911
ingreso	-4.8146	2.015	-2.389	0.021	-8.879	-0.750

Sin remuestrear, a partir de los residuos: la columna std err que vimos en la clase 04. El error estándar de la pendiente es 2,02, cerca del 1,8 del bootstrap. Las demás columnas se van a ir pintando a medida que lleguen sus conceptos.

El intervalo, en el summary

	coeficiente	error estándar			intervalo del 95%	
	coef	std err	t	P> t	[0.025	0.975]
const	38.3352	1.773	21.622	0.000	34.760	41.911
ingreso	-4.8146	2.015	-2.389	0.021	-8.879	-0.750

Las columnas [0.025 0.975]: $b \pm 2,02 \cdot EE = [-8,9; -0,75]$. El primer uso del error estándar, ahora para la pendiente. Es el intervalo que dibujamos en la clase 04 sin saber todavía de dónde salía.

Con y sin bootstrap

	Sin bootstrap: la fórmula	Con bootstrap
cómo se obtiene	una fórmula, a partir de los residuos de las 45 comunas	2.000 remuestras de las 45 comunas, con reemplazo
pendiente	-4,81	-4,81, la observada
error estándar	2,02	1,82, la desviación de las 2.000
intervalo del 95%	$[-8,9; -0,75]$, $b \pm 2,02 \cdot EE$	$[-9,1; -2,1]$, percentiles 2,5 y 97,5
qué necesita	que exista la fórmula para ese estadístico, y supuestos sobre los residuos	solo el computador, y que la muestra represente a la población
sirve para	medias y coeficientes de regresión	cualquier estadístico

Dos caminos al mismo número, con la misma muestra de 45 comunas: se parecen, y ningún intervalo incluye el 0. La fórmula es instantánea, pero existe solo para algunos estadísticos y supone cosas sobre los residuos.

¿Cuándo bootstrap y cuándo la fórmula?

La fórmula (std err, t)

- Medias y coeficientes de una regresión bien planteada
- Errores independientes y de varianza pareja
- Exacta, instantánea y viene en el summary

El bootstrap


- Cuando no hay fórmula para ese estadístico: mediana, percentil, razón, R^2 , la métrica de un modelo
- Cuando los supuestos fallan: colas largas con pocos datos, varianza que cambia
- No supone campana: lee el histograma

Ninguno arregla una muestra sesgada ni filas dependientes. Si se pueden hacer los dos, hacerlos: si coinciden, la fórmula está bien.

La fórmula es exacta e instantánea cuando el estadístico es una media o un coeficiente y los errores se portan bien. El bootstrap sirve para cualquier estadístico y no supone forma de campana.

5. Segundo uso del error estándar: el contraste


Todo número que sale de una muestra se mueve;
el error estándar mide cuánto, y se usa de dos formas



Prueba de hipótesis y valor p: ¿la pendiente es real o azar?

Qué tiene que ver p con la regresión

El valor p en la regresión: ¿la inclinación de la recta es una señal, o ruido de la muestra?




p pequeño: demasiado raro para ser azar, la relación probablemente es real · p grande: no se distingue del ruido (no hay evidencia, que no es lo mismo que no exista)

Con $p = 0,021$ concluimos que la relación entre ingreso y duración probablemente es real; con $p = 0,40$ no podríamos distinguir la recta del ruido. Lo que p no dice: si el efecto es grande, ni si es causal.


Dos vistas: intervalo y prueba

la recta de la clase 04
duración = $38,3 - 4,8 \cdot \text{ingreso}$



Vista 1, el intervalo: la campana centrada en $-4,8$, lo que obtuvimos; el 95% central va de $-8,9$ a $-0,75$ y el 0 queda fuera. Vista 2, la prueba: la misma campana centrada en 0, lo que diría el azar sin relación; nuestra $-4,8$ cae en la cola, $t = -2,4$ y $p = 0,021$. Son la misma afirmación, mirada desde el intervalo o desde la prueba.

La lógica de la prueba



Cuidado con la lectura: p es la probabilidad de los datos si H_0 fuera cierta, no la probabilidad de que H_0 sea cierta. $p = 0,021$ no dice que haya un 2% de probabilidad de que la pendiente real sea 0.

t, en el summary

	coeficiente	error estándar	t = coef / EE		intervalo del 95%	
	coef	std err	t	P> t	[0.025	0.975]
const	38.3352	1.773	21.622	0.000	34.760	41.911
ingreso	-4.8146	2.015	-2.389	0.021	-8.879	-0.750

$t = -4,81 / 2,02 = -2,39$: la pendiente está a 2,4 errores estándar del cero. Falta saber qué tan raro es eso, y con qué distribución se mide.

t y p: la fórmula y el código

$$t = \frac{b}{EE(b)} \quad p = 2 \cdot (1 - F(|t|))$$

t: a cuántos errores estándar del cero está la pendiente b · p: el área de las dos colas de la t de Student más allá de t

Con las comunas: t = -4,81 / 2,02 = -2,39, p = 0,021

```
b, ee = modelo.params["ingreso"], modelo.bse["ingreso"]
t = b / ee                                # -2.39

# Dos colas de la t con n - 2 grados de libertad
p = 2 * (1 - stats.t.cdf(abs(t), df=43))    # 0.021
```

F es la acumulada de la t de Student con $n - 2 = 43$ grados de libertad: la normal con un margen extra, porque σ se estimó con s. Por eso el intervalo usa 2,02 y no 1,96.

El summary completo


	coeficiente	error estándar	$t = \text{coef} / \text{EE}$	valor p	intervalo del 95%	
	coef	std err	t	$P > t $	[0.025	0.975]
const	38.3352	1.773	21.622	0.000	34.760	41.911
ingreso	-4.8146	2.015	-2.389	0.021	-8.879	-0.750

La última columna, $P > |t| = 0,021$: si la pendiente real fuera 0, un t así de lejos ocurre el 2,1% de las veces. Las cinco columnas, pintadas: coeficiente, error estándar, intervalo, t y valor p .

La respuesta a la pregunta


- ▶ **La pendiente que nos dio el modelo no es azar: en las comunas de mayor ingreso los viajes duran menos, unos 4,8 minutos menos por cada millón de pesos de ingreso medio (entre 0,75 y 8,9).**
- ▶ Lo que la sostiene: $p = 0,021$ y el intervalo $[-8,9; -0,75]$ no incluye el 0. Con 45 comunas apenas cruza el umbral, porque p depende del efecto y del tamaño de la muestra.
- ▶ Que un efecto sea estadísticamente significativo no dice que sea grande: el tamaño lo da el coeficiente, y su precisión, el intervalo.
- ▶ Correlación no es causalidad, tampoco con p pequeño.

Por qué esto importa en ciencia de datos



Un modelo también sale de una muestra: sus coeficientes, sus predicciones y sus métricas se mueven, y medir ese movimiento es lo que permite comparar modelos y detectar el sobreajuste.

Síntesis del bloque 1



Supone errores independientes y de varianza pareja. No dice si el efecto es grande (eso lo dice el coeficiente) ni si es causal.

Inferir es pasar de la muestra a la población cuantificando la incertidumbre. La herramienta es el error estándar, y se usa dos veces: en el intervalo y en la prueba.

Recreo

Al volver: una respuesta que es sí o no

Bloque 2 · La pregunta: ¿sí o no?

- ▶ **¿Qué clientes de una tarjeta de crédito dejarán de pagar? ¿Qué pasajeros del Titanic sobrevivieron? La respuesta no es un número: es un sí o un no.**
- ▶ La regresión de la clase 04 explica un número con una recta. Ahora la misma recta explica un sí o no, y para eso hay que pasarla por una curva.
- ▶ El modelo no entrega el sí o el no: entrega una probabilidad. Decidir es cortarla en un umbral, y toda decisión tiene dos formas de equivocarse.
- ▶ Dos ejemplos: 10.000 clientes de tarjeta de crédito (James et al.) y 891 pasajeros del Titanic. Los datos están en `datos/clase06/` del repositorio.

El mapa del bloque

El modelo no predice el sí o el no: predice una probabilidad.

La decisión, y sus dos errores, la ponemos nosotros

**1. Una respuesta
que es sí o no**

y vale 0 o 1:
Bernoulli y la
proporción p

**2. La recta
no sirve**

probabilidades
fuera de $[0, 1]$

3. La logística

la recta dentro
de una S;
 e^b multiplica
los odds

**4. El mismo
summary**

coef, std err,
 z , p ; varias x
y dummies

5. Clasificar

umbral, matriz
de confusión,
falsos positivos
y negativos

Una respuesta que es sí o no

La variable y vale 1 o 0, y se quiere explicar con una o más x

¿El cliente dejará
de pagar?

y: sí (1) o no (0)

x: deuda en la tarjeta,
ingreso, si estudia

¿El pasajero
sobrevivió?

y: sí (1) o no (0)

x: sexo, clase del
pasaje, edad

¿El correo
es spam?

y: sí (1) o no (0)

x: palabras, adjuntos,
remitente

¿El paciente tiene
la enfermedad?

y: sí (1) o no (0)

x: resultado de un
examen, edad

¿El hogar
tiene auto?

y: sí (1) o no (0)

x: ingreso, personas,
sector de la ciudad

los dos ejemplos de hoy

la misma pregunta en otros dominios

En todos los casos la respuesta y vale 1 (sí) o 0 (no), y hay una o más variables x con las que explicarla. Es la misma estructura de la regresión: y a partir de x.

Los datos: los clientes de la tarjeta



Default (ISLR): 10.000 clientes de tarjeta de crédito, una fila por cliente. Las primeras 6 filas de las 4 columnas

default	student	balance	income
No	No	729,53	44.361,63
No	Yes	817,18	12.106,13
No	No	1.073,55	31.767,14
No	No	529,25	35.704,49
No	No	785,66	38.463,50
No	Yes	919,59	7.491,56

Antes de graficar nada, la tabla. Cada fila es un cliente. default dice si dejó de pagar y student si es estudiante, las dos en Yes o No; balance es la deuda en la tarjeta después del pago mensual e income el ingreso anual, en dólares.

Ejemplo 1: ¿qué clientes dejan de pagar?

Ejemplo 1: 10.000 clientes de tarjeta de crédito; 333 dejaron de pagar (3,3%)



Datos del libro de James et al.: 10.000 clientes, su deuda en la tarjeta (lo que deben después del pago mensual), su ingreso anual y si son estudiantes. Solo 333 dejaron de pagar: el sí es raro, y eso importará al final.

Bernoulli y la proporción

La proporción p : los clientes que dejaron de pagar, sobre el total

La columna `no_paga` vale 1 (dejó de pagar) o 0 (paga)

clientes: 10.000


con un 1 (dejaron de pagar): 333

proporción $p = 333 / 10.000 = 0,033$

Es la media de la columna de ceros y unos: la fracción de unos.

Un cliente tomado al azar es una Bernoulli(p): no paga con probabilidad $p = 0,033$ y paga con probabilidad $1 - p = 0,967$.

Lo que sigue: que esa p dependa de la deuda de cada cliente.




p es la proporción de unos en la columna: 333 de 10.000, 0,033. Un cliente al azar es una Bernoulli con esa p : la distribución más simple, dos resultados y una probabilidad. La logística modela esa p según la deuda.

El mapa del bloque

El modelo no predice el sí o el no: predice una probabilidad.

La decisión, y sus dos errores, la ponemos nosotros



La probabilidad de no pagar, por tramo de deuda

En cada tramo de deuda, la fracción de clientes que dejó de pagar estima la probabilidad de no pagar

Un tramo es un intervalo de deuda. El tramo 7: de 1.800 a 2.100 dólares

clientes en el tramo: **229**


de ellos, dejaron de pagar: **114**

fracción que no paga = $114 / 229 = 0,50$

Esa fracción es la probabilidad de no pagar de un cliente con esa deuda, estimada con los datos: un punto del gráfico.

Otro tramo, el 4, de 900 a 1.200 dólares: $19 / 2.117 = 0,009$



Y así con los nueve tramos de 300 dólares.



Se agrupan los clientes por tramo de deuda y en cada tramo se cuenta cuántos dejaron de pagar. La fracción es la probabilidad de no pagar de ese tramo, estimada con los datos: casi 0 con deudas bajas, 0,50 entre 1.800 y 2.100 dólares, 1 desde los 2.400. Los nueve puntos tienen forma de S: esa es la curva que hace falta.

Por qué la recta no sirve

Los mismos datos de dos formas: cada punto gris es un cliente (0 o 1); cada punto azul, la fracción que no paga en un tramo de deuda




Nada impide ajustar la recta de la clase 04 con el 0/1 como respuesta, pero una probabilidad vive entre 0 y 1: con deuda 0 la recta da -0,08, y a los 2.000 dólares da 0,18 cuando la fracción real es 0,50. Las fracciones suben en forma de S, y la curva de la derecha las sigue: es la regresión logística.

El mapa del bloque

El modelo no predice el sí o el no: predice una probabilidad.

La decisión, y sus dos errores, la ponemos nosotros



De la probabilidad a los odds (chances)

Otra forma de decir la probabilidad: los odds (chances). Con ellas desaparece el techo de 1

Los odds (chances) de un sí: cuántos síes hay por cada no

P = 0,8



8 síes por 2 noes: odds $8 / 2 = 4$ (4 a 1)

P = 0,5




5 síes por 5 noes: odds $5 / 5 = 1$ (1 a 1)

P = 0,2



2 síes por 8 noes: odds $2 / 8 = 0,25$ (1 a 4)

odds = $P / (1 - P)$: la probabilidad del sí dividida por la del no



Los odds (chances) son la probabilidad dicha de otra forma: cuántos síes por cada no. P = 0,8 son odds de 4 a 1. Van de 0 a infinito, así que ya no tienen el techo de 1, pero siguen sin poder ser negativas.

Despejar P: de la recta a la sigmoide

Recordatorio
 $\text{odds} = P / (1 - P)$

Del modelo a la sigmoide: despejar P en cuatro pasos

1. $\log \frac{P}{1-P} = z$

el modelo: el log de los odds es la recta, $z = a + b \cdot x$

2. $\frac{P}{1-P} = e^z$

se deshace el logaritmo con e: los odds son e elevado a la recta

3. $P = e^z (1 - P) \Rightarrow P(1 + e^z) = e^z$ se multiplica por (1 - P) y se juntan los P a la izquierda

4. $P = \frac{e^z}{1 + e^z} = \frac{1}{1 + e^{-z}}$


se despeja P: la sigmoide. Dividir arriba y abajo por e elevado a z da la segunda forma

El modelo dice que el logaritmo de los odds es la recta z: el logaritmo puede ser cualquier número, positivo o negativo, y ahí sí cabe una recta. Para volver a la probabilidad hay que despejar P, y el resultado es la sigmoide: por eso el exponente es la recta.

La misma relación en tres escalas


La misma relación entre la deuda y el no pagar, en tres escalas: la recta vive en la segunda, la S es cómo se ve en la tercera

1. En odds (chances): una exponencial




tomar el
logaritmo

2. En log de los odds: una recta



despejar P
(slide 15)

3. Despejando P de la recta: la S



Con los tramos de la slide anterior. En odds, los puntos suben como una exponencial; en log de los odds (chances), siguen una recta, y eso es lo que el modelo supone; y al despejar P como en la slide anterior, la S. La recta y la S son la misma relación vista en dos escalas.

La regresión logística

La regresión logística: la recta $a + b \cdot x$ en la escala del log de los odds (chances); la sigmoide es la misma recta vista en probabilidades

$$\text{el modelo: } \log \frac{P}{1 - P} = a + b x$$

$$\text{despejando P: } P(y = 1 \mid x) = \frac{1}{1 + e^{-(a + b x)}}$$

$P(y = 1 \mid x)$

$a + b \cdot x$

$P / (1 - P)$

log de los odds

e^b

la probabilidad de un sí, dado el valor de x

la misma recta de la regresión lineal

los odds (chances): sí contra no. Con $P = 0,8$, odds 4 a 1

la escala en que la recta es recta: el logit

cuánto se multiplican los odds (chances) por cada unidad de x

El modelo dice que el log de los odds (chances) es una recta en x . Despejar P de esa ecuación da la sigmoide: por eso el exponente es $a + b \cdot x$, es la misma recta. Y como sumar b en un logaritmo es multiplicar afuera, e^b dice cuánto se multiplican los odds por cada unidad de x , igual que el modelo en logaritmo de la clase 04.

De dónde salen los números: el summary

	coeficiente	error estándar	$z = \text{coef} / \text{EE}$	valor p	intervalo del 95%	
	coef	std err	z	$P> z $	[0.025	0.975]
Intercept	-10.6513	0.361	-29.491	0.000	-11.359	-9.943
deuda_100	0.5499	0.022	24.952	0.000	0.507	0.593

smf.logit entrega el mismo summary que la regresión lineal: coef son $a = -10,65$ y $b = 0,55$, con su error estándar, su intervalo y su valor p. La única diferencia es z en lugar de t : con 10.000 clientes la referencia es la normal, y $P>|z|$ se lee igual que $P>|t|$. Esos dos coeficientes son los que van en la fórmula de la slide siguiente.

El modelo ajustado a los clientes

La fórmula de la slide anterior, con los números del ajuste a los 10.000 clientes

$$\log \frac{P}{1-P} = -10,65 + 0,55 \cdot \text{deuda}_{100}$$

$$P(\text{no paga} \mid \text{deuda}) = \frac{1}{1 + e^{-(-10,65 + 0,55 \cdot \text{deuda}_{100})}}$$

a = -10,65

el log de los odds de un cliente sin deuda: en probabilidad, 0,00002

b = 0,55

cada 100 dólares más de deuda le suman 0,55 al log de los odds


e^b = 1,73

esos mismos 100 dólares multiplican los odds (chances) por 1,73

Con 2.000 dólares: $\text{deuda}_{100} = 20$, $z = -10,65 + 0,55 \cdot 20 = 0,35$, $P = 1 / (1 + e^{(-0,35)}) = 0,59$


deuda_{100} es la deuda en la tarjeta en cientos de dólares: 2.000 dólares son 20. Se divide por 100 para que b se lea por cada 100 dólares, como el ingreso en millones de la clase 04. a fija el nivel con deuda 0, b dice cuánto sube el log de los odds (chances) por cada 100 dólares, y e^b lo dice como multiplicación.

La sigmoide



La función que apareció al despejar. Recibe la recta $z = a + b \cdot x$, el log de los odds, y devuelve la probabilidad: en $z = 0$ (odds 1 a 1) vale 0,5; hacia la derecha se acerca a 1 y hacia la izquierda a 0, sin pasarse nunca.

Cómo se lee b: los odds (chances) se multiplican



Con la deuda en cientos de dólares, $b = 0,55$ y $e^b = 1,73$: cada 100 dólares más de deuda multiplican los odds (chances) de no pagar por 1,7. En probabilidades: 0,01 con 1.000 dólares, 0,08 con 1.500, 0,59 con 2.000.

Probabilidad y odds no son lo mismo

La misma información en dos escalas: P va de 0 a 1; los odds, de 0 a infinito

P de no pagar	odds = $P / (1 - P)$	se lee
0,10	$0,10 / 0,90 = 0,11$	1 moroso por cada 9 que pagan
0,50	$0,50 / 0,50 = 1$	1 a 1
0,59	$0,59 / 0,41 = 1,41$	1,4 morosos por cada uno que paga
0,80	$0,80 / 0,20 = 4$	4 a 1
0,95	$0,95 / 0,05 = 19$	19 a 1

Con probabilidades chicas se parecen (0,10 y 0,11); a medida que P sube se separan, porque los odds no tienen techo.

Al revés: $P = \text{odds} / (1 + \text{odds})$. Con odds 1,41, $P = 1,41 / 2,41 = 0,59$.

El coeficiente b habla de los odds, no de la probabilidad: cada 100 dólares multiplican los odds por 1,73, para cualquier deuda. En probabilidad no hay un número fijo: de 1.000 a 1.500 dólares P pasa de 0,01 a 0,08, y de 1.500 a 2.000 salta a 0,59.

La logística en statsmodels

```
import statsmodels.formula.api as smf
modelo = smf.logit("no_paga ~ deuda_100", data=clientes).fit()

np.exp(modelo.params["deuda_100"])    # e^b = 1,73
modelo.predict(nuevos_clientes)       # probabilidades
```

- smf usa fórmulas del tipo $y \sim x$ y agrega el intercepto solo: es el equivalente del sm.OLS con `add_constant` de la clase 04, con logit en lugar de ols. predict entrega probabilidades, no síes y noes. El código completo está en el notebook.

Cinco clientes ficticios

Cinco clientes ficticios: de la deuda a la probabilidad de no pagar, con el modelo ajustado

cliente	deuda (dólares)	deuda ₁₀₀	$z = -10,65 + 0,55 \cdot \text{deuda}_{100}$	odds = e^z	$P = 1 / (1 + e^{(-z)})$
A	500	5	$-10,65 + 0,55 \cdot 5 = -7,90$	0,000	0,000
B	1.000	10	$-10,65 + 0,55 \cdot 10 = -5,15$	0,006	0,006
C	1.500	15	$-10,65 + 0,55 \cdot 15 = -2,40$	0,090	0,083
D	2.000	20	$-10,65 + 0,55 \cdot 20 = 0,35$	1,41	0,586
E	2.500	25	$-10,65 + 0,55 \cdot 25 = 3,10$	22,11	0,957

La probabilidad no sube de a saltos iguales: de 1.000 a 1.500 dólares pasa de 0,01 a 0,08, y de 1.500 a 2.000 salta a 0,59. Eso es la S.


Los odds, en cambio, sí se multiplican por lo mismo en cada tramo: por $e^{(0,55 \cdot 5)} = 15,6$ cada 500 dólares.

El mismo cálculo de predict, a mano: la deuda en cientos de dólares entra a la recta z , e^z da los odds y la sigmoide da P . La probabilidad no sube parejo: casi nada hasta los 1.000 dólares, 0,08 a los 1.500 y 0,59 a los 2.000. Los odds sí se multiplican por lo mismo en cada tramo.

El mapa del bloque



El modelo no predice el sí o el no: predice una probabilidad.

La decisión, y sus dos errores, la ponemos nosotros



Varias variables: el caso del estudiante

Ser estudiante y la deuda se confunden: los estudiantes deben más, y la deuda es lo que explica el no pago



Solos, los estudiantes dejan de pagar más (4,3% contra 2,9%). Pero deben más, y a igual deuda dejan de pagar menos. Es la confusión de variables de la clase 04: el coeficiente de una x cambia según qué otras x estén en el modelo.

El mecanismo, con 200 clientes inventados

Un ejemplo inventado de 200 clientes: dentro de cada tramo los estudiantes pagan mejor, en el total pagan peor

	no estudiantes	estudiantes
deuda baja	80 clientes, 4 no pagan 5%	20 clientes, 0 no pagan 0%
deuda alta	20 clientes, 10 no pagan 50%	80 clientes, 32 no pagan 40%
total	100 clientes, 14 no pagan 14%	100 clientes, 32 no pagan 32%

80 de los 100 estudiantes están en deuda alta, y solo 20 de los 100 no estudiantes: el total compara un grupo endeudado con uno que no lo está

En deuda baja los estudiantes pagan mejor (0% contra 5%) y en deuda alta también (40% contra 50%). Pero 80 de los 100 estudiantes tienen deuda alta, donde casi todos pagan mal, y solo 20 de los 100 no estudiantes: por eso en el total parecen peores (32% contra 14%). El modelo con solo estudiante lee el total; el modelo con la deuda compara dentro de cada tramo. Ninguno se equivoca: responden preguntas distintas.

El summary con estudiante y deuda

	coeficiente					
	coef	std err	z	P> z	[0.025	0.975]
Intercept	-10.7495	0.369	-29.115	0.000	-11.473	-10.026
deuda_100	0.5738	0.023	24.748	0.000	0.528	0.619
estudiante	-0.7149	0.148	-4.846	0.000	-1.004	-0.426

Solo con estudiante, el coeficiente era 0,40 ($e^{0,40} = 1,50$: los odds de un estudiante eran 1,5 veces las de un no estudiante). Se agrega la deuda y el coeficiente se da vuelta: pasa a -0,71, y $e^{(-0,71)} = 0,49$. A igual deuda, los odds (chances) de no pagar de un estudiante son la mitad.

El summary con varias variables

	coeficiente	error estándar	$z = \text{coef} / \text{EE}$	valor p	intervalo del 95%	
	coef	std err	z	$P > z $	[0.025	0.975]
Intercept	-10.8690	0.492	-22.079	0.000	-11.834	-9.904
deuda_100	0.5737	0.023	24.737	0.000	0.528	0.619
ingreso_miles	0.0030	0.008	0.370	0.712	-0.013	0.019
estudiante	-0.6468	0.236	-2.738	0.006	-1.110	-0.184

Estudiante es una dummy, como el modo de la clase 04: $e^{(-0,65)} = 0,52$, a igual deuda e ingreso, los odds de un estudiante son la mitad. El ingreso no aporta ($p = 0,71$), pero no por la deuda: el ingreso y ser estudiante van juntos, 18 mil dólares contra 40 mil, así que con estudiante adentro el ingreso no dice nada nuevo.

El modelo final, escrito: los clientes

Ejemplo 1, el modelo final escrito: deuda y estudiante (el ingreso no aporta y queda fuera)

$$\log \frac{P}{1-P} = a + b_1 \cdot \text{deuda}_{100} + b_2 \cdot \text{estudiante}$$

$$z = -10,75 + 0,57 \cdot \text{deuda}_{100} - 0,71 \cdot \text{estudiante}$$

$$P = \frac{1}{1 + e^{-z}} \quad \text{con } z \text{ la recta de arriba}$$

Dos clientes con 2.000 dólares de deuda ($\text{deuda}_{100} = 20$), uno estudiante y otro no:

cliente	deuda ₁₀₀	estudiante	z	P(no paga)
estudiante	20	1	$-10,75 + 0,57 \cdot 20 - 0,71 \cdot 1 = 0,01$	0,50
no estudiante	20	0	$-10,75 + 0,57 \cdot 20 - 0,71 \cdot 0 = 0,73$	0,67

El modelo que queda: deuda y estudiante, porque el ingreso no aportaba. Para un cliente concreto se reemplazan sus valores, sale z, y la sigmoide lo convierte en probabilidad. Es lo que hace predict.

Cuatro clientes ficticios, con dos variables

Cuatro clientes ficticios con el modelo de dos variables: la dummy estudiante suma su coeficiente solo cuando vale 1

cliente	deuda	estudiante	$z = -10,75 + 0,57 \cdot \text{deuda}_{100} - 0,71 \cdot \text{estudiante}$	P
A	1.500	no (0)	$-10,75 + 0,57 \cdot 15 - 0,71 \cdot 0 = -2,14$	0,11
B	1.500	sí (1)	$-10,75 + 0,57 \cdot 15 - 0,71 \cdot 1 = -2,86$	0,05
C	2.000	no (0)	$-10,75 + 0,57 \cdot 20 - 0,71 \cdot 0 = 0,73$	0,67
D	2.000	sí (1)	$-10,75 + 0,57 \cdot 20 - 0,71 \cdot 1 = 0,01$	0,50

A igual deuda, ser estudiante resta 0,71 a z: los odds se multiplican por $e^{(-0,71)} = 0,49$, la mitad. Con 2.000 dólares, el no estudiante tiene $P = 0,67$ y el estudiante $P = 0,50$. El ingreso quedó fuera porque no aportaba.

El mismo cálculo que antes, ahora con dos variables: la deuda entra multiplicada por su coeficiente y la dummy estudiante suma el suyo solo cuando vale 1. A igual deuda, el estudiante tiene menos probabilidad de no pagar, porque su coeficiente es negativo.

Los datos: los pasajeros del Titanic


Titanic: 891 pasajeros, una fila por pasajero. Las primeras 6 filas de las 4 columnas que usa el modelo, de las 15 del archivo

survived	pclass	sex	age
0	3	male	22,0
1	1	female	38,0
1	3	female	26,0
1	1	female	35,0
0	3	male	35,0
0	3	male	NaN

El segundo dataset, con la misma mirada previa. survived vale 1 si el pasajero sobrevivió, pclass es la clase del pasaje (1, 2 o 3) y sex el sexo. La edad falta en 177 pasajeros, y el modelo usa los 714 que sí la tienen.

Ejemplo 2: ¿quién sobrevivió en el Titanic?

Ejemplo 2: 891 pasajeros del Titanic, 38% sobrevivió. Dos variables categóricas y una numérica (la edad)



El 74% de las mujeres sobrevivió contra el 19% de los hombres, y la clase del pasaje ordena a ambos grupos. Dos variables categóricas y la edad: la logística con dummies, otra vez.

El summary del Titanic: cómo leer varios e^b

	coeficiente	error estándar	$z = \text{coef} / \text{EE}$	valor p	intervalo del 95%	
	coef	std err	z	$P> z $	[0.025	0.975]
Intercept	1.2542	0.360	3.485	0.000	0.549	1.960
sexo[T.mujer]	2.5228	0.207	12.164	0.000	2.116	2.929
C(clase)[T.2]	-1.3098	0.278	-4.710	0.000	-1.855	-0.765
C(clase)[T.3]	-2.5806	0.281	-9.169	0.000	-3.132	-2.029
edad	-0.0370	0.008	-4.831	0.000	-0.052	-0.022

Cada coeficiente compara con una referencia: $e^{2,52} = 12,5$, a igual clase y edad, los odds de una mujer son 12 veces las de un hombre; $e^{(-2,58)} = 0,08$, la tercera clase tiene el 8% de los odds de la primera; cada año de edad las multiplica por 0,96.

El modelo final, escrito: el Titanic

Ejemplo 2, el modelo final escrito: las categóricas entran como dummies, con hombre y primera clase como referencia

$$\log \frac{P}{1-P} = a + b_1 \cdot \text{mujer} + b_2 \cdot \text{clase2} + b_3 \cdot \text{clase3} + b_4 \cdot \text{edad}$$

$$z = 1,25 + 2,52 \cdot \text{mujer} - 1,31 \cdot \text{clase2} - 2,58 \cdot \text{clase3} - 0,037 \cdot \text{edad}$$


$$P = \frac{1}{1 + e^{-z}} \quad \text{con } z \text{ la recta de arriba}$$

Dos pasajeros de 30 años: una mujer de primera clase y un hombre de tercera. Las dummies valen 1 o 0:

pasajero	mujer	clase2	clase3	edad	z	P(sobrevive)
mujer, primera clase	1	0	0	30	$1,25 + 2,52 - 0,037 \cdot 30 = 2,67$	0,94
hombre, tercera clase	0	0	1	30	$1,25 - 2,58 - 0,037 \cdot 30 = -2,44$	0,08

Cada categórica aporta una dummy por categoría, menos la de referencia: mujer (contra hombre), clase2 y clase3 (contra primera). Una mujer de primera clase de 30 años lleva mujer = 1 y las dos dummies de clase en 0: $z = 2,7$ y $P = 0,93$. Un hombre de tercera de 30 años lleva clase3 = 1: $z = -2,4$ y $P = 0,08$.

Predecir con varias variables: cuatro perfiles




La recta suma el aporte de cada variable y la sigmoide lo convierte en probabilidad: 0,94 para una mujer de primera clase, 0,08 para un hombre de tercera, ambos de 30 años. Los perfiles del medio quedan cerca de 0,5: ahí el modelo duda.


El mapa del bloque

El modelo no predice el sí o el no: predice una probabilidad.

La decisión, y sus dos errores, la ponemos nosotros



Clasificar: de la probabilidad a la decisión



Volvemos a los clientes del banco, con el modelo de la deuda. Un clasificador convierte P en sí o no con un umbral. Con 0,5, el modelo dice "no paga" desde los 1.937 dólares de deuda. A la derecha del corte hay clientes que sí pagan; a la izquierda, clientes que no: los dos errores.

La matriz de confusión de los clientes

La matriz de confusión: lo real contra lo predicho, umbral 0,5, 10.000 clientes		
	predicho "no paga"	predicho "paga"
real: no paga	Verdadero positivo 100 el modelo acertó	Falso negativo 233 era sí, el modelo dijo no
real: paga	Falso positivo 42 era no, el modelo dijo sí	Verdadero negativo 9.625 el modelo acertó

Los 10.000 clientes del banco, con el modelo de la deuda y el umbral 0,5. Lo real en las filas, lo predicho en las columnas. La diagonal son los aciertos; fuera de ella, los dos errores con nombre propio: falso negativo (era sí, dijo no) y falso positivo (era no, dijo sí). De 333 clientes que no pagan, el modelo detecta 100.

Falso positivo y falso negativo

Los dos errores no cuestan lo mismo, y cuál cuesta más depende del problema, no del modelo

Falso positivo

el modelo dice sí y era no

- banco: le niega la tarjeta a un cliente que sí iba a pagar (pierde un cliente)
- correo: un mensaje real termina en la carpeta de spam
- examen médico: tratar a alguien sano

Falso negativo

el modelo dice no y era sí

- banco: le da la tarjeta a un cliente que no va a pagar (pierde el dinero)
- correo: un spam llega a la bandeja de entrada
- examen médico: no detectar la enfermedad

El modelo no sabe cuál error cuesta más: eso lo pone el problema. Para el banco, un falso negativo es dinero perdido; para un examen médico, una enfermedad sin detectar, como en la clase 01. Cómo elegir el umbral según ese costo queda para la clase de evaluación de modelos.

La exactitud: qué fracción acertó

La exactitud (accuracy): de todas las predicciones, qué fracción acertó, y la base con la que hay que compararla

La matriz de la slide anterior, umbral 0,5

	predicho "no paga"	predicho "paga"
real: no paga	Verdadero positivo 100 el modelo acertó	Falso negativo 233 era sí, el modelo dijo no
real: paga	Falso positivo 42 era no, el modelo dijo sí	Verdadero negativo 9.625 el modelo acertó

Exactitud: la fracción de clientes en que el modelo acertó

aciertos: la diagonal de la matriz

$$\text{verdaderos positivos} + \text{verdaderos negativos} = 100 + 9.625 = 9.725$$

$$\text{exactitud} = 9.725 / 10.000 = 0,973$$

Sin modelo, decir que todos pagan también es un clasificador.


Su exactitud es la fracción de clientes que de verdad pagan:

$$\text{base} = 9.667 / 10.000 = 0,967$$

La siguiente slide compara los dos números.

La medida más obvia de un clasificador: los aciertos, la diagonal de la matriz, divididos por el total. 0,973 parece muy bueno. Pero cualquier exactitud hay que compararla con la de no tener modelo: predecir siempre la clase más frecuente, aquí "paga".

La exactitud engaña cuando el sí es raro




El modelo acierta el 97,3% y decir que nadie deja de pagar acierta el 96,7%, que es $1 - 0,033$: uno menos la proporción que no paga. De los 333 clientes que no pagan, el modelo detecta 100. Con un sí raro, la exactitud mide sobre todo lo fácil: los noes.

El Titanic como clasificador

Con un sí frecuente (41%), la exactitud sí dice algo: el modelo gana 20 puntos a la base

Titanic: 714 pasajeros con edad conocida, umbral 0,5

	predicho "sobrevivió"	predicho "murió"
real: sobrevivió	Verdadero positivo 207 el modelo acertó	Falso negativo 83 era sí, el modelo dijo no
real: murió	Falso positivo 68 era no, el modelo dijo sí	Verdadero negativo 356 el modelo acertó




La base es decir que todos murieron: de los 714 pasajeros con edad, 424 murieron, así que acierta $424 / 714 = 0,59$ y falla en los 290 que sobrevivieron. El modelo acierta el 79%: con un sí frecuente la exactitud sí informa, 20 puntos sobre la base. Los errores: 83 falsos negativos, pasajeros que sobrevivieron y el modelo daba por muertos, y 68 falsos positivos.


Evaluar fuera de la muestra

Un modelo se evalúa con datos que no vio al ajustarse: la medida honesta de cuánto acierta (promedio de 20 repartos)

Separar antes de ajustar



La exactitud que vale es la de los datos de prueba




Medir la exactitud en los mismos datos con que se ajustó el modelo es hacer trampa: el modelo ya los vio. Se separa una parte de prueba antes de ajustar. Con modelos simples como estos las dos cifras se parecen; con modelos más flexibles, la de prueba es la única que vale.

La respuesta a la pregunta del bloque

- ▶ **El modelo no dice quién deja de pagar ni quién sobrevivió: dice con qué probabilidad. Un cliente con 2.000 dólares de deuda tiene 0,59; una mujer de primera clase, 0,94.**
- ▶ El sí o el no lo ponemos nosotros con el umbral, y cada umbral deja una cantidad de falsos positivos y de falsos negativos. Cómo elegirlo según el costo de cada error queda para la clase de evaluación de modelos.
- ▶ La exactitud sola no basta: hay que mirar los dos errores por separado, y medirlos en datos que el modelo no vio.

Síntesis del bloque 2

El modelo no predice el sí o el no: predice una probabilidad. La decisión, y sus dos errores, la ponemos nosotros



Con un sí raro la exactitud engaña: contar los falsos negativos y los falsos positivos. Y medir en datos de prueba, no en los de entrenamiento.

Una Bernoulli, una recta pasada por la sigmoide, la lectura con e^b y el summary, y la decisión con un umbral que deja dos errores.

Próximas clases

- ▶ **Viernes 9 de octubre: Certamen 1, unidades 1 a 5. Entra el bloque 1 de hoy (inferencia); la regresión logística no entra.**
- ▶ Viernes 23 de octubre: introducción al aprendizaje automático, sesgo y varianza, regularización. Se entrega la Tarea 2.
- ▶ Lo que quedó pendiente de hoy, sensibilidad y especificidad, la elección del umbral y la curva ROC, va en la clase de evaluación de modelos.

Referencias

Efron, B. y Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall.

Wasserstein, R. L. y Lazar, N. A. (2016). The ASA Statement on p-Values: Context, Process, and Purpose. The American Statistician, 70(2), 129-133.

James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). An Introduction to Statistical Learning with Applications in R (2a ed.), capítulo 4 (regresión logística) y sección 5.1 (conjunto de validación). Springer. Disponible en statlearning.com.

Diez, D., Çetinkaya-Rundel, M. y Barr, C. (2019). OpenIntro Statistics (4a ed.), capítulo 9.5 (regresión logística). Disponible en openintro.org.

Datos: Encuesta Origen Destino Santiago 2012 (Sectra); Default, del libro de James et al. (statlearning.com); Titanic, del repositorio seaborn-data (github.com/mwaskom/seaborn-data).